

Avaliação de Algoritmos de Aprendizagem de Máquina para Classificação de Atividade Molecular

Estudo comparativo entre kNN, Árvore de Decisão e Random Forest no dataset hiva_agnostic (OpenML / TabArena)

Alunos: Lucas Emanuel Cândido de Oliveira – 2025021360

Wesley Vieira Eduardo - 2025021359

Disciplina de Data Science — 2026

1. Introdução

Este relatório apresenta um estudo comparativo entre três algoritmos clássicos de aprendizagem supervisionada — k-Nearest Neighbors (kNN), Árvore de Decisão (Decision Tree) e Random Forest — aplicados a um problema real de classificação com múltiplas classes. O objetivo é avaliar o desempenho preditivo de cada algoritmo utilizando métricas amplamente adotadas na literatura, como acurácia e F1-score. A escolha do dataset e dos algoritmos segue as diretrizes estabelecidas na disciplina, que exige um problema de classificação obtido do repositório público OpenML, com mais de 10 atributos e mais de 1000 instâncias.

2. Algoritmos de Aprendizagem de Máquina

- 2.1. k-Nearest Neighbors (kNN) O kNN é um algoritmo de aprendizagem baseado em instâncias, que classifica uma nova amostra de acordo com a classe predominante entre seus k vizinhos mais próximos no espaço de atributos (COVER; HART, 1967). É um método simples, não paramétrico, que não possui uma fase de treinamento propriamente dita — apenas armazena os dados de treino para consulta no momento da predição. Neste trabalho foi utilizado $k = 5$, com distância Euclidiana como métrica padrão.
- 2.2. Árvore de Decisão (Decision Tree) As árvores de decisão constroem um modelo em forma de estrutura hierárquica, na qual cada nó interno representa um teste sobre um atributo, cada ramo representa o resultado desse teste e cada folha representa uma classe (QUINLAN, 1986). É um algoritmo interpretável, capaz de capturar relações não lineares entre os atributos, mas propenso a overfitting quando não é limitado em profundidade.
- 2.3. Random Forest O Random Forest é um método de ensemble que combina múltiplas árvores de decisão treinadas em subamostras diferentes dos dados (bagging) e de subconjuntos aleatórios de atributos, agregando suas predições por votação majoritária (BREIMAN, 2001). Essa combinação tende a reduzir a variância do modelo em relação a uma única árvore de decisão, geralmente resultando em melhor capacidade de generalização.

3. Experimentos

3.1 Banco de Dados

O dataset utilizado foi o hiva_agnostic, disponibilizado publicamente no OpenML e curado pela equipe do TabArena como parte do estudo TabArena Tabular ML IID Study (TABARENA, 2026). Os dados têm origem no desafio 'Agnostic Learning vs. Prior Knowledge' (GUYON et al., 2007) e descrevem propriedades estruturais de moléculas, com o objetivo de prever a atividade de compostos químicos. O conjunto de dados é composto por 3.845 instâncias e 1.617 atributos binários (0 ou 1), representando propriedades da estrutura molecular de cada composto.

3.2. Métricas

Foram utilizadas duas métricas para avaliação dos modelos: acurácia, que mede a proporção de instâncias classificadas corretamente em relação ao total; e F1-score (weighted), que calcula a média harmônica entre precisão e revocação para cada classe e pondera o resultado pelo suporte (número de instâncias) de cada uma. Essa ponderação faz com que a métrica leve em conta o desbalanceamento entre as classes, dando peso proporcional ao tamanho de cada uma. A avaliação foi feita com um split de 70% dos dados para treino e 30% para teste, utilizando os três modelos com hiperparâmetros padrão (kNN com $k=5$, Random Forest com 100 árvores).

3.3 Resultado

A Tabela apresenta os resultados de acurácia e F1-score (weighted) obtidos para cada um dos três algoritmos avaliados.

MODELO	ACCURACY	F1- SCORE(WEIGHTED)
kNN	0,9627	0,9445
Decision Tree	0,9133	0,9196
Random Forest	0,9627	0,9445

O kNN e o Random Forest obtiveram os melhores resultados, com acurácia de 96,27% e F1-weighted de 0,9445, superando a Decision Tree, que obteve 91,33% de acurácia e 0,9196 de F1-weighted. Esse padrão é esperado, já que o Random Forest é um método de ensemble que combina várias árvores de decisão, tendendo a generalizar melhor do que uma única árvore.

4. Conclusão

Este trabalho comparou três algoritmos de aprendizagem de máquina — kNN, Decision Tree e Random Forest — na tarefa de classificação de

atividade molecular no dataset hiva_agnostic. Os resultados mostraram que o kNN e o Random Forest apresentaram desempenho superior ao da Decision Tree isolada, tanto em acurácia quanto em F1-score (weighted), o que está alinhado com a literatura, já que métodos de ensemble tendem a reduzir a variância e generalizar melhor do que uma única árvore de decisão.

5. Referencias

https://www.openml.org/search?type=data&sort=runs&status=active&qualities.NumberOfInstances=between_1000_10000&qualities.NumberOfFeatures=between_1000_10000&qualities.NumberOfClasses=gte_2&id=46933

<https://scikit-learn.org/stable/index.html>